

Projeto Final

Pipeline de ETL Integrado:

Uma análise do perfil dos conteúdos da renomada Netflix

Integrantes ENIAC :

Alessandra Machado
Caroline Cruz
Clara Maria
Dayane Lurdes
Elaine Castro
Maria Elacide
Tandara Jesus
Eduarda Lima

Sobre o projeto:

Esta é a documentação consolidada do projeto final do Bootcamp de Business Intelligence da WoMakersCode, do Squad ENIAC.

Temos como objetivo final deste relatório, aplicar técnicas e ferramentas de análise de dados para transformar informações brutas de streaming da Netflix em conhecimento estratégico sobre o conteúdo produzido.

A iniciativa busca não apenas gerar valor a partir dos dados, mas também fortalecer as competências do grupo em Power BI, Python, modelagem de dados, storytelling analítico e construção de relatórios executivos.



Introdução e contexto da escolha do dataset:

A indústria de streaming cresce rapidamente no mundo, com cada vez mais marcas buscando um espaço no mercado. Essa competitividade exige análises estratégicas do catálogo para orientar decisões de mercado.

A Netflix, como líder global do setor, expande continuamente seu portfólio, buscando equilibrar diversidade, escala e alcance internacional. Este projeto analisa o perfil dos conteúdos adicionados à plataforma entre 2016 e 2021, avaliando tipo, gênero, país de origem e evolução anual.

A partir dos dados brutos, desenvolvemos um pipeline completo, da extração à visualização, para gerar insights sobre prioridades de conteúdo a serem produzidos e tendências de mercado.





Problema central - (O que o projeto se propõe a resolver?)

Qual é o perfil de conteúdo que a Netflix mais prioriza e como esse conteúdo se relaciona com o volume de títulos lançados anualmente, pensando em tendências de mercado e possibilidades de investimento?

Objetivo principal:

Analizar e quantificar o catálogo da Netflix (2016-2021) para determinar o conteúdo que recebe maior prioridade (Filmes vs. Séries, gêneros e países de produção).

O objetivo é fornecer insights claros sobre a estratégia de conteúdo da plataforma, validar se a tendência observada deverá ser seguida em futuras produções e identificar padrões de crescimento que justifiquem próximos investimentos



Objetivos específicos (entregáveis):

- Processamento de dados (SQL & Python): Transformar dados brutos do catálogo Netflix em um conjunto de dados estruturado e pronto para análise.
- Análise (SQL & Power BI): Mapear e visualizar o crescimento anual do volume de lançamentos (entre 2016 e 2021), separando a evolução de Filmes vs. Séries.
- Identificação de padrões (SQL & Power BI):
 - Identificar e rankear os gêneros predominantes no catálogo.
 - Mapear a distribuição de conteúdo por país de origem (priorizando produções originais).
- Entrega de Insights (Power BI): Dashboard interativo (Power BI) que relaciona o perfil do catálogo com a evolução anual e forneça a base para a resposta final sobre a estratégia de expansão e mercado da Netflix

Relevância do tema:

O tema é altamente relevante por motivos estratégicos, analíticos e de mercado, especialmente no contexto de plataformas de streaming como a Netflix. É importante entender o cenário de algo tão presente no mercado e na vida das pessoas, além de ser algo em constante expansão e que podemos contribuir com estes insights.



Organização do projeto:

O trabalho foi desenvolvido de forma colaborativa com divisão de responsabilidades:

- **ETL (Google Colab)**: limpeza, padronização e criação da camada gold
- **SQL/SQLite**: estruturação do banco e validação dos dados
- **Análise e Storytelling**: interpretação dos resultados e construção das hipóteses
- **Power BI**: dashboards, cálculos e visualizações
- **Documentação**: consolidação técnica e revisão final

Metodologia aplicada:

- 1) **Extração**: leitura e exploração inicial do dataset bruto
- 2) **Transformação**: tratamento de inconsistências, criação de colunas e normalização
- 3) **Carga**: armazenamento em SQLite para consumo no BI
- 4) **Visualização**: dashboards com métricas, tendências e indicadores



Planejamento do projeto



Base de dados

Formato dos dados: (CSV) dados tabulares simples.

Tamanho e complexidade:

- O dataset tem 8.807 linhas e 12 colunas principais (show_id, type, title, director, cast, country, date_added, release_year, rating, duration, listed_in, description).
- O tamanho do arquivo : 3,4 MB.

Escolha do dataset:

- Permite análises de perfil de conteúdo.
- Facilita avaliação de tendências ao longo do tempo.



Arquivo Editar Ver Inserir Formatar Dados Ferramentas Extensões Ajuda

Menus | fx show_id


	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	show_id	type	title	director	cast	country	date_added	release_year	rating	duration	listed_in	description		
2	s1	Movie	Dick Johnson	Is Kirsten Johnson		United States	September 25, 2020	2020	PG-13	90 min	Documentaries	As her father nears the end of his life, filmmaker Ki		
3	s2	TV Show	Blood & Water		Ama Qamata, K!	South Africa	September 24, 2021	2021	TV-MA	2 Seasons	International TV	After crossing paths at a party, a Cape Town teen s		
4	s3	TV Show	Ganglands	Julien Leclercq	Sami Bouajila, Tracy Gotoas, San	September 24, 2021	2021	TV-MA	1 Season	Crime TV Shows	To protect his family from a powerful drug lord, skill			
5	s4	TV Show	Jailbirds	New Orleans			September 24, 2021	2021	TV-MA	1 Season	Docuseries, Rea Feuds, flirtations and toilet talk go down among the			
6	s5	TV Show	Kota Factory		Mayur More, Jite India		September 24, 2021	2021	TV-MA	2 Seasons	International TV	In a city of coaching centers known to train India's 1		
7	s6	TV Show	Midnight Mass	Mike Flanagan	Kate Siegel, Zach Gilford, Hamish	September 24, 2021	2021	TV-MA	1 Season	TV Dramas, TV	The arrival of a charismatic young priest brings glo			
8	s7	Movie	My Little Pony: A	Robert Cullen, Jr.	Vanessa Hudgens, Kimiko Glenn, September 24, 2021	2021	PG	91 min	Children & Famil	Equestria's divided. But a bright-eyed hero believes				
9	s8	Movie	Sankofa	Haile Gerima	Kofi Ghanaba, O	United States, G	September 24, 1993	TV-MA	125 min	Dramas, Indepe	On a photo shoot in Ghana, an American model slips			
10	s9	TV Show	The Great British	Andy Devonshire	Mel Giedroyc, Si	United Kingdom	September 24, 2021	2021	TV-14	9 Seasons	British TV Shows	A talented batch of amateur bakers face off in a 10-		
11	s10	Movie	The Starling	Theodore Melfi	Melissa McCarthy	United States	September 24, 2021	PG-13	104 min	Comedies, Dram	A woman adjusting to life after a loss contends with			
12	s11	TV Show	Vendetta: Truth, Lies and The Mafia				September 24, 2021	TV-MA	1 Season	Crime TV Shows	Sicily boasts a bold "Anti-Mafia" coalition. But what			
13	s12	TV Show	Bangkok Breakin	Kongkiat Komes	Sukollawat Kanarot, Sushar Man	September 23, 2021	TV-MA	1 Season	Crime TV Shows	Struggling to earn a living in Bangkok, a man joins				
14	s13	Movie	Je Suis Karl	Christian Schwo	Luna Wedler, Jai	Germany, Czech	September 23, 2021	TV-MA	127 min	Dramas, Internat	After most of her family is murdered in a terrorist bo			
15	s14	Movie	Confessions of a Bruno Garotti		Klara Castanho, Lucca Picon, Júli	September 22, 2021	TV-PG	91 min	Children & Famil	When the clever but socially-awkward Teté joins a				
16	s15	TV Show	Crime Stories: India Detectives				September 22, 2021	TV-MA	1 Season	British TV Shows	Cameras following Bengaluru police on the job offe			
17	s16	TV Show	Dear White People		Logan Browning	United States	September 22, 2021	TV-MA	4 Seasons	TV Comedies, T	Students of color navigate the daily slights and slip			
18	s17	Movie	Europe's Most D	Pedro de Echave García, Pablo Azorín	Williams	September 22, 2020	TV-MA	67 min	Documentaries,	Declassified documents reveal the post-WWII life o				
19	s18	TV Show	Falsa identidad		Luis Ernesto Fra	Mexico	September 22, 2020	TV-MA	2 Seasons	Crime TV Shows	Strangers Diego and Isabel flee their home in Mexi			
20	s19	Movie	Intrusion	Adam Salky	Freida Pinto, Logan Marshall-Gre	September 22, 2021	TV-14	94 min	Thrillers	After a deadly home invasion at a couple's new dre				
21	s20	TV Show	Jaguar		Blanca Suárez, Iván Marcos, Ósc	September 22, 2021	TV-MA	1 Season	International TV	In the 1960s, a Holocaust survivor joins a group of				
22	s21	TV Show	Monsters Inside:	Olivier Megaton			September 22, 2021	TV-14	1 Season	Crime TV Shows	In the late 1970s, an accused serial rapist claims m			
23	s22	TV Show	Resurrection: Ertugrul		Engin Altan Düzy	Turkey	September 22, 2018	TV-14	5 Seasons	International TV	When a good deed unwittingly endangers his clan,			
24	s23	Movie	Avvai Shanmug	K.S. Ravikumar	Kamal Hassan, Meena, Gemini G	September 21, 1996	TV-PG	161 min	Comedies, Interr	Newly divorced and denied visitation rights with his				



Planejamento do projeto

Fonte de dados

Nome do dataset: **Netflix Movies and TV Shows** (também chamado “netflix-shows”) por *shivamb* no Kaggle. [Baselight](#)



Questionamentos que permeiam a análise:

- Qual é a distribuição de **filmes vs séries** no Netflix ao longo dos anos?
- Quais são os gêneros mais frequentes e como eles variam por país?
- Quais gêneros são mais adicionados por usuários?
- Como podemos analisar a relevância de títulos por país e ano adicionado?



Desenvolvimento do pipeline


Fonte: Kaggle — “Netflix Movies and TV Shows” por shivamb:

Transformações necessárias: Limpeza, criação de tabelas, métricas, (camada gold), como o Google Collab.

Destino: banco de dados Sqlite e (Power BI)

Visualização:

- Relatório, dashboard (Power BI)
- Gráfico de linha: lançamentos por Gênero.
- Gráfico de barras: distribuição de País x Ano.
- Cards: Total de títulos / Filmes x Series / Títulos anual.



Desenvolvimento do pipeline no Google Collab

Primeira etapa: EXTRAÇÃO



Você pode acompanhar a construção nesse link:

<https://colab.research.google.com/drive/1oWVQSI7Dt01RaCvzovo8kzl03x-4vdqs?usp=sharing> - Fazer a leitura de arquivos locais (**CSV - Comma – Separated Values**)

```
# Importando a biblioteca
import pandas as pd
import numpy as np
import sqlite3
import gdown

1. EXTRAÇÃO

# Carregamento inicial dos dados brutos
# ID do arquivo
arquivo_id = "1A4MVsMqteVw2aNvIAGNvwciOs6rEMMkv"

# Monta a URL para o gdown
url = f"https://drive.google.com/uc?id={arquivo_id}"
output = "netflix.csv"

gdown.download(url, output, quiet=False)

try:
    df.netflix_titles = pd.read_csv("netflix.csv")
```



Desenvolvimento do pipeline

Primeira etapa: EXTRAÇÃO REALIZADA

- # Importando a biblioteca
- # Carregamento inicial dos dados brutos
- # ID do arquivo
- # Monta a URL para o gdown
- # Exibição de tipos de colunas
- # print("\Contagem de valores nulos por Coluna:")
- # print("Visualizando linhas com dados faltantes:")
- # print("\Estatísticas")



Desenvolvimento do pipeline

Segunda etapa: TRANSFORMAÇÃO (Google Colab)

```
# Criada uma cópia para a camada silver
df_silver = df.netflix_titles.copy()

# Limpeza Inicial
# Removidas duplicatas
df_silver.drop_duplicates(inplace=True)

# Para validar se há duplicidades
numero_de_duplicatas_restantes = df_silver.duplicated().sum()
if numero_de_duplicatas_restantes == 0:
    print("✅ Sucesso! Todas as duplicatas foram removidas.")
else:
    print(f"⚠️ Atenção! Ainda existem {numero_de_duplicatas_restantes} duplicatas.")

✅ Sucesso! Todas as duplicatas foram removidas.

# Tratamento de nulos: Preencher com 'Desconhecido'
dicionario = {
```



Desenvolvimento do pipeline

Segunda etapa: TRANSFORMAÇÃO REALIZADAS

```
# Criada uma cópia para a camada silver
# Limpeza Inicial
    -Removidas duplicatas)
# Para validar se há duplicidades
# Tratamento de nulos: Preencher com 'Desconhecido'
# Para validar se há nulos
    -Lista das colunas que foram tratadas)
    -Série com a contagem de nulos nas colunas tratadas
# Removidos espaços em branco no início e fim de todas as colunas de texto
# Validar espaços em branco nos textos
    -Identificar as colunas de texto (object)
    -Checar se há valores que começam ou terminam com espaço
# Padronizados nomes para Primeira Maiúscula
colunas_titulos = ['title', 'director', 'cast']

    -Checa se o valor original é diferente do valor após a re-aplicação do .str.title()

        -Se forem diferentes, o valor original (após a sua execução) estava no formato correto.
# Dicionário de unificação dos países
    -Aplicação da unificação

# Dicionário de Classificação Etária para padrão Brasil
# Livre, 10+, 12+, 14+, 16+, 18+
# Verificar se a nova coluna 'rating br' tem 6 classificações
```

```
# Ajuste datas e tipos
# Convertidas date_added para datetime
# Checa o tipo de dado da coluna 'date_added'
# Criadas colunas de Ano e Mês de adição
# Calculado intervalo entre o lançamento e a adição na plataforma
# Colunas para conferir (-Seleciona 5 linhas aleatórias)
# Duração - Separar valor numérico da unidade (min vs seasons)
# Cria uma coluna de resumo da duração
# Converter para Inteiro INT
# Amostra visual (-Seleciona 5 linhas aleatórias para verificação)
# Novas Colunas (- Gênero principal (primeiro da lista)
    - País principal (primeiro da lista)
# Tabela dimensão para 'genero_principal'
    -Criação do ID único (chave primária)
    -Começa o ID em 1 para ser mais amigável
    -Chave Estrangeira
    -Adiciona a chave estrangeira na tabela principal (df_silver)

# Tabela de dimensão para 'pais_principal'
    -ID único (chave primária)
    -Começa o ID em 1
    -Chave Estrangeira
    -Adiciona a chave estrangeira na tabela principal (df_silver)
```



Desenvolvimento do pipeline


Terceira etapa: CARREGAMENTO



- Salvar os dados no banco de dados **banco SQLite** e armazenamento no banco de dados (DBeaver)
- Arquivo final tratado (camada gold) deve estar em um formato para ser consumido na **ferramenta de BI**



Dashboard desenvolvido (Netflix_Dashboard_BI.pbix no GitHub)



Dashboard desenvolvido

Visão Detalhada do Perfil de Conteúdo e do Crescimento Anual de Lançamentos

Página 1



Página 2



Gênero


Pesquisar

- Action & Adventure
- Anime Features
- Anime Series
- British TV Shows
- Children & Family Mo...
- Classic & Cult TV
- Classic Movies



Faixas de Lançamento por Ano Adicionado

Faixa: Lançado há 1 Ano, Lançado há 10 Anos, Lançado há 3 Anos, Lançado há 5 Anos, Lançado há mais de 10 Anos, Lançamentos



Insights

Crescimento claro por gênero até 2020, com queda visível em 2021.

Ação & Aventura, Comédia e Drama puxam a alta ao longo dos anos.

A maioria dos títulos adicionados em 2019–2021 é de conteúdos lançados há mais de 10 anos, indicando forte retrocatálogo..

Tendência aponta para mistura de catálogo antigo + gêneros populares para sustentação de oferta.

Documentação - GitHub

Disponível neste link:

https://github.com/alessandramdsz/pipeline_ETL_projeto_final_ENIAC/blob/main/README.md

Documentamos todas as etapas primordiais para o desenvolvimento do projeto no GitHub.

As etapas para execução e visualização dos dados são:

1. Clonar o repositório
2. Preparar o ambiente
3. Instalar dependências
4. Executar o Notebook de ETL
5. Executar o banco de dados
6. Abrir o Dashboard no Power BI
7. Reproduzir o pipeline completo



Documentação - GitHub - Se preparando para executar

Para execução do projeto, deve-se confirmar se possui os seguintes programas/ferramentas instalados:

- Python 3.8
- Jupyter Notebook ou Google Colab
- SQLite3
- DBeaver (opcional)
- Power BI Desktop

Além de confirmar se está com as dependências instaladas (pip instal):

- Pandas (ler, limpar e tratar o *datasource* do projeto)
- Numpy (Criação de arrays)
- Matplotlib (visualizando e entendendo os dados)os dados.
- Sqlite3 (Criar o banco, preencher com os dados tratados e fazer as consultas com o pipeline)



Documentação - GitHub - Executando o projeto

Recomenda-se a execução por meio do Google Colab:

- Acesse o Colab
- Faça upload do notebook disponível neste repositório
- Faça upload do arquivo CSV na pasta/content
- Execute todas as células na ordem



The screenshot shows a Google Colab notebook cell with the following Python code:

```
[45] Os
# CONEXÃO COM BANCO DE DADOS LOCAL (SQLite)
conn = sqlite3.connect('projeto.netflix.db')

# Salvando as tabelas no banco de dados
try:
    df_gold_titulos.to_sql('dim_titulos', conn, if_exists='replace', index=False)
    df_gold_generos.to_sql('fato_generos', conn, if_exists='replace', index=False)
    df_gold_paises.to_sql('fato_paises', conn, if_exists='replace', index=False)
    df_dim_generos.to_sql('dim_generos', conn, if_exists='replace', index=False)
    df_dim_paises.to_sql('dim_paises', conn, if_exists='replace', index=False)
    df_gold_generos.to_sql('ponte_generos.todos', conn, if_exists='replace', index=False)
    df_gold_paises.to_sql('ponte_paises.todos', conn, if_exists='replace', index=False)

    print("Carga realizada com sucesso! Tabelas criadas")

except Exception as e:
    print(f'Erro na carga: {e}')
finally:
    conn.close()

print('\n--- Pipeline Finalizado ---')
print("O arquivo 'projeto.netflix.db' está pronto para ser conectado ao Power Bi")
```

The output of the cell shows the success message:

```
... Carga realizada com sucesso! Tabelas criadas
--- Pipeline Finalizado ---
O arquivo 'projeto.netflix.db' está pronto para ser conectado ao Power Bi
```



Análise e conclusão estratégica

A análise de dashboard mostra o **crescimento anual de lançamentos**, destacando a evolução no volume de novos conteúdos ao longo dos anos. Observa-se que há uma tendência de **expansão, estabilidade até 2020 seguido de uma redução em 2021**, facilitando a compreensão do ritmo de crescimento e da eficiência das estratégias adotadas.

- **Tipo de conteúdo:** A plataforma prioriza filmes, que representam aproximadamente 70% do catálogo analisado, demonstrando foco em volume e diversidade de títulos de longa-metragem.
- **Gêneros predominantes:** Drama, Comédia e Ação formam o nicho principal do catálogo. Esta prioridade em gêneros de apelo global garante a ampla aceitação e escalabilidade em diferentes mercados internacionais.
- Os Estados Unidos lideram amplamente a **origem** dos títulos, seguidos pela Índia. Isso indica a manutenção da base ocidental e o crescimento estratégico em hubs regionais para o desenvolvimento de conteúdo local.



- Há um investimento crescente em **nichos de alto engajamento**, como crime, anime e séries, para reter públicos específicos.
- O alto volume de lançamentos anuais é mantido por meio do forte uso de **retrocatalogo** (conteúdos lançados há mais de 10 anos, mas adicionados à plataforma entre 2019 e 2021), indicando que a **mistura de conteúdo antigo e novos títulos é fundamental para sustentar a plataforma**.



Conclusão:

Como esse conteúdo se relaciona com o volume de títulos lançados anualmente, pensando em tendências de mercado e possibilidade de investimento?

A estratégia de conteúdo da Netflix se baseia em um equilíbrio entre custo, volume e diversidade, o que é importante para a competitividade no mercado de *streaming*. A plataforma prioriza o filmes de apelo global, sustentado pelo forte uso de retrocatálogo e por uma expansão geográfica estratégica.



Interpretação estratégica:

- Foco em conteúdos de **apelo global** para escalar presença internacional. Prioridade em **filmes** são essenciais para escalar a presença internacional e a aceitação.
- **Retrocatálogo** aumenta oferta rápido e com menor custo.
- Conteúdo **regional** que complementa a expansão em mercados locais.

Implicações para investimento:

- Investir em **gêneros globais** (drama/comédia/ação) tende a ter maior retorno.
- A aquisição de direitos de distribuição de **retrocatálogo** representa uma oportunidade de baixo custo e alto volume, fundamental para manter a oferta e a retenção.
- O investimento em mercados regionais e nichos de alto engajamento (crime, anime) indica potencial de crescimento futuro e de retenção de audiência.

Em suma, a Netflix prioriza filmes de apelo global, reforçados por retrocatálogo e expansão geográfica, mantendo o volume alto com uma estratégia de equilíbrio que maximiza o alcance global e o retorno sobre o investimento.



Obrigada!

Squad ENIAC

Alessandra Machado
Caroline Cruz
Clara Maria
Dayane Lurdes
Elaine Castro
Maria Elacide
Tandara Jesus

